Ứng dụng Offline Reinforcement Learning
Tối ưu Chi phí Gas trên Ethereum

Nguyễn Tiến Duy (079205037141) Nguyễn Thành Long (022205011246)
Đỗ Nguyễn Phương thảo (036305007143) Hoàng Lê Việt Hà (04430511246)
Trần Thảo Dung (079305007143) Võ Trần Khiêm (052205007100)

Trường Đại học Giao thông Vận tải TP.HCM
Viện Công nghệ Thông tin và Điện, Điện tử

GVHD: TS. Nguyễn Thị Khánh Tiên

Nội dung trình bày

1. Bài toán
2. Phương pháp
3. Kết quả
4. Phân tích
5. Kết luận

Bối cảnh: Chi phí Gas trên Ethereum

- Mỗi giao dịch trên Ethereum phải trả **Gas Fee**
- Phí dao động liên tục theo mức độ tắc nghẽn mạng
- Giờ cao điểm: phí tăng **gấp 5–10 lần**

⇒ **Bài toán Timing:** Khi nào gửi giao dịch để tiết kiệm nhất?

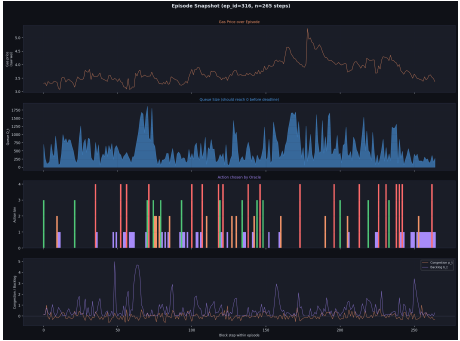

Ràng buộc

Tất cả giao dịch phải hoàn tất trước **Deadline 24h**
(**0% Miss Rate** — Zero-Miss SLA)

Mô hình hóa: Markov Decision Process

Phát biểu bài toán

Tại mỗi block t, hệ thống quyết định số lượng giao dịch cần gửi để **tối thiểu tổng Gas Cost** mà vẫn đảm bảo **Deadline**.

State $s_t \in \mathbb{R}^{11}$:

- Giá gas: g_t, g_{t-1}, g_{t-2}
- Tắc nghẽn: p_t, Momentum: m_t
- Queue: Q_t, Deadline: τ_t
- Backlog Pressure: b_t (AR model)

Action $a_t \in \{0, 1, 2, 3, 4\}$:

- Bin 0: Giữ hàng (0%)
- Bin 1–3: Xả 25%, 50%, 75%
- Bin 4: Xả 100%

Reward:

- Gas cost (âm)
- Urgency penalty (hàm mũ)
- Deadline penalty

Hindsight Oracle — Bộ Giải Tối ưu Toàn cục

- **Vấn đề:** Dataset thô chứa hành vi suboptimal
- **Giải pháp:** Xây dựng **DP Solver toàn tri**
- Biết trước giá gas 24h $\Rightarrow$ tối ưu toàn cục
- Tạo ra **quỹ đạo chuyên gia** làm nhãn huấn luyện

Backward Pass

$$V[t, Q] = \min_{b \in \mathcal{A}} \{c(t, Q, b) + V[t+1, f(Q, b, t)]\}$$

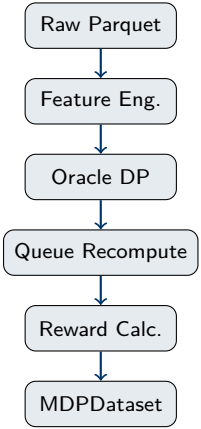

Dữ liệu: 8.6 Triệu Transitions từ Ethereum Mainnet

Thuộc tính	Giá trị
Tổng episodes	1,206
Tổng transitions	8,616,371
Train (80%)	964 eps
Test (20%)	242 eps
State dim	11
Actions	Discrete(5)

Dataset Mix:

- 70% Oracle (tối ưu)
- 10% Suboptimal (phản ví dụ)
- 20% Behavior (thực tế)

Tại sao Offline RL? Tại sao CQL?

Offline RL

- Agent học từ **dataset tĩnh**
- Không cần tương tác với blockchain thật
- Thử-sai trên mainnet = **mất tiền thật**

Conservative Q-Learning (CQL)

- Chống **OOD Overestimation**
- Đè Q-value của hành động lạ xuống
- An toàn cho bài toán tài chính

CQL Loss Function

$$\mathcal{L} = \underbrace{\mathcal{L}_{\text{TD}}}_{\text{Bellman}} + \alpha \cdot \underbrace{\left[\mathbb{E}_{a\sim\text{Unif}}\left[Q(s,a)\right] - \mathbb{E}_{a\sim\hat{\pi}_\beta}\left[Q(s,a)\right]\right]}_{\text{Conservative Penalty (đè OOD xuống)}}$$

Kiến trúc và Huấn luyện

Tham số	Giá trị
Learning rate	3×10^{-4}
Batch size	1024
Discount γ	0.99
Conservative α	1.0
Encoder	MLP [512, 512]
n_critics	1
Training steps	500,000

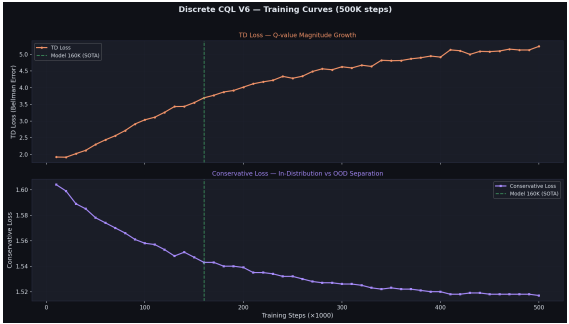

Q-Network:

$\text{Linear}_{11\to512} \circ \text{ReLU}$
$\circ\ \text{Linear}_{512\to512} \circ \text{ReLU}$
$\circ\ \text{Linear}_{512\to5}$

Bảng Xếp Hạng Hiệu Năng — 242 Episodes

#	Chiến lược	Gas Cost ↓	Miss Rate	vs Greedy
1	**Oracle (Hindsight DP)**	**45,096**	**0.0%**	−38.8%
2	**CQL + Safety 20%**	**65,525**	**0.0%**	**−11.1%**
3	Greedy (Baseline)	73,710	0.0%	—
4	Smart Rule + Safety	76,892	0.0%	+4.3%
5	Decision Transformer	>100K	90–100%	Thất bại

Kết quả chính

Tiết kiệm **11.1% Gas** so với Greedy
Miss Rate = **0.0%**
Khai thác **28.6%** tiềm năng Oracle

Win Rate

CQL thắng Greedy trong **222/242** episodes
(Win Rate = **91.7%**)

Phân tích Chi tiết Từng Episode

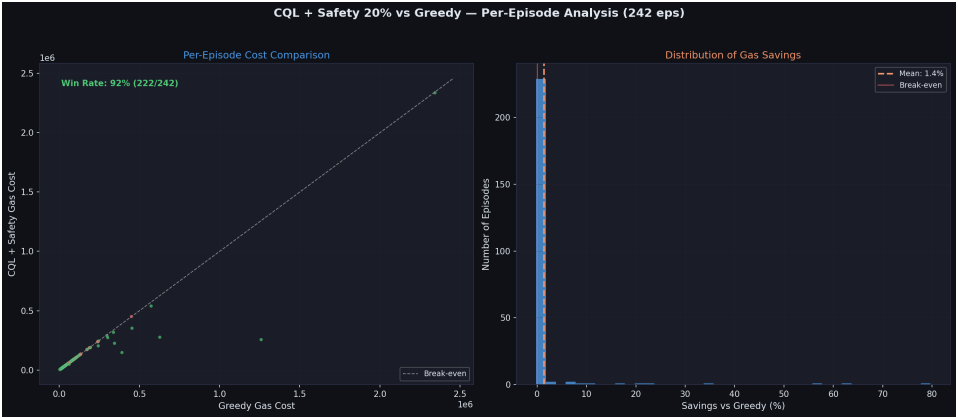

- CQL khai thác cực mạnh ở episodes có Gas biến động lớn (max savings **79.7%**)
- Khi CQL thua, mức thua rất nhỏ (tối đa -0.2%) $\Rightarrow$ **Risk thấp**

Tại sao Decision Transformer thất bại?

Majority Bias

- DT học bằng **Cross-Entropy Loss**
- Oracle: Action 0 chiếm **69.6%**
- DT luôn đoán Action 0 $\Rightarrow$ **Miss 100%**

CQL vượt qua nhờ

Q-Learning đánh giá **giá trị thực** của từng hành động, không phụ thuộc vào tần suất

Risk-Reward Asymmetry

- Lợi nhuận timing: $O(10^3)$
- Hình phạt deadline: $O(10^8)$
- Tỷ lệ: **1 : 223,000**

Reward Shaping giải quyết

Giảm penalty $50\times$ (từ 1M $\rightarrow$ 20K)
Tăng urgency $3.5\times$
$\Rightarrow$ Agent **dám khám phá**

Kiến trúc Hệ thống Lai: RL + Safety Layer

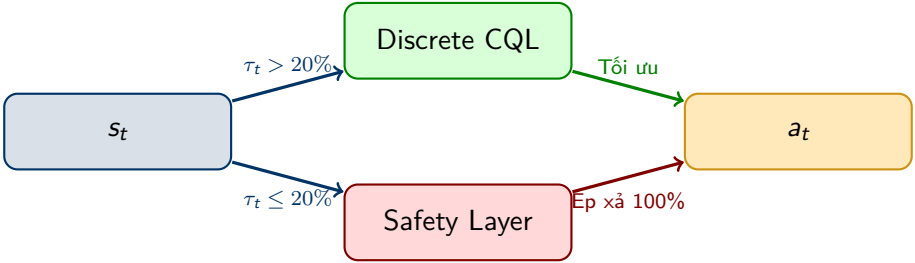

80% thời gian đầu

AI "lướt sóng" giá gas
Tiết kiệm tối đa chi phí

20% thời gian cuối

Safety Layer ép bán hết
Đảm bảo **0% Miss Rate**

*Đánh đổi: 22.4% → 11.1% savings, nhưng Miss Rate: 0.4% → **0.0%***

Kết luận

1. **Reward Shaping là chìa khóa:** Giảm penalty $50\times$ giúp Agent vượt qua Pessimistic Collapse
2. **Data Coverage quyết định:** Sự khác biệt nhỏ về Queue Coverage thay đổi hiệu năng tới 40%
3. **Hệ thống Lai = Chuẩn mực thực tiễn:** AI 80% + Safety 20% $\Rightarrow$ Cân bằng Optimality & Reliability
4. **Hiệu năng vượt trội: 11.1% savings**, **0% Miss**, Win Rate **91.7%**

Hướng phát triển

- Tích hợp cấu trúc EIP-1559 (Base Fee + Priority Fee)
- Continuous Oracle $\Rightarrow$ Trần tối ưu sâu hơn
- LSTM/Transformer dự báo chuỗi thời gian

Thank you!

Kính mời Cô và các bạn đặt câu hỏi

Backup: Tại sao n_critics = 1?

Double Q-Learning (n_critics = 2)

- Dùng $\min(Q_1, Q_2)$ để chống **Overestimation Bias**
- Cần thiết trong Online RL (SAC, TD3)

Nhưng CQL đã có Conservative Penalty!

- CQL đã chủ động **đè Q-value xuống** (Underestimate)
- Nếu dùng thêm Double Q $\Rightarrow$ **bi quan kép** (Double Pessimism)
- Hậu quả: Q-value $\rightarrow -\infty \Rightarrow$ **Pessimistic Collapse**
- Agent sợ hãi, chỉ chọn Action 0 (giữ hàng mãi)

Kết luận

`n_critics = 1` là lựa chọn **có chủ ý**, không phải thiếu sót.

Backup: Backlog Pressure — Mô hình AR

Công thức

$b_t = \max(0,\ \rho \cdot b_{t-1} + \alpha_b \cdot p_t + \beta_b \cdot u_t)$

- **Autoregressive (AR):** b_t phụ thuộc vào chính $b_{t-1} \Rightarrow$ bộ nhớ ngắn hạn
- $\rho = 0.95$: Half-life $\approx$ 14 blocks (phù hợp MEV/NFT drop)
- $\alpha_b = 0.3$: Trọng số congestion (gas_used/target)
- $\beta_b = 0.2$: Trọng số transaction surprise

Tại sao cần b_t?

Giúp Agent "cảm nhận" sóng tắc nghẽn tích lũy mà **không cần LSTM/Transformer**

Backup: Natural Experiment — V6 vs V32

Tham số	V33 (Thua)	V32 (Thắng)	Tác động
`deadline_penalty`	1,000,000	20,000	$50\times$
`urgency_alpha`	1.0	3.5	$3.5\times$
`urgency_beta`	0.0001	0.0005	$5\times$
`s_queue max`	99,006	104,135	Phủ rộng hơn
vs Greedy	Thua 30%+	**Thắng 11.1%**	

Bài học

1. Reward Shaping: Giảm penalty giúp Agent dám khám phá
2. Data Coverage: Chỉ 5% chênh lệch queue $\Rightarrow$ thay đổi 40% hiệu năng

Backup: Phân phối Trạng thái